

Human Freedom Index · EDA com PCA + Clustering · LiU 2026

Capítulo 1

Cronograma — menos de 1 semana

Voce tem pouco tempo. Siga este cronograma na ordem. Nao pule etapas — cada uma alimenta a proxima.

Dia	O que fazer	Tempo	Entregavel
Dia 1	Assistir StatQuest PCA (2 videos) + baixar dataset do Lisam	2-3h	Entender PCA
Dia 2	Rodar o codigo R completo, olhar os graficos, anotar o que ve	3h	Graficos prontos
Dia 3	Escrever Introducao + Metodos (as partes mais faceis)	3h	3 paginas escritas
Dia 4	Escrever Resultados PCA + Clustering com seus graficos reais	3h	5 paginas escritas
Dia 5	Discussao + Conclusao + Revisar + Appendix + Submeter	2h	Paper submetido

Se ficar sem tempo: a parte mais importante e a interpretacao dos resultados. Uma analise bem interpretada com graficos reais vale mais do que texto perfeito sem interpretacao.

Pergunta de Pesquisa e Literatura

Use esta pergunta — ela responde exatamente o que o assignment pede:

"What latent dimensions structure human freedom across countries, and do nations cluster into distinct freedom profiles?"

2.1 Por que essa pergunta funciona

- Usa "latent dimensions" — que o assignment menciona como exemplo válido
- Justifica o uso de PCA (dimensões latentes) E clustering (perfis distintos)
- Tem resposta genuinamente interessante — o HFI tem estrutura rica
- Permite citar literatura relevante e gratuita

2.2 Literatura para citar (tudo grátis online)

Autor	Obra	O que diz	Onde usar
Vasquez & McMahon (2018)	Human Freedom Index Report	Define as dimensões do HFI	Introdução + Métodos
Sen (1999)	Development as Freedom	Liberdade e multidimensional	Introdução
Freedom House	Freedom in the World	Abordagem alternativa	Discussão
Cato Institute	Methodology (website)	Como as variáveis foram construídas	Métodos

Frases prontas: "Human freedom is a multidimensional concept encompassing personal, civil, and economic liberties (Vasquez & McMahon, 2018)." // "EDA allows exploration of latent structure without imposing a priori assumptions."

Estrutura Completa do Paper

O paper deve ter ~7 paginas sem appendix, espacamento 1.5, PDF com username LiU.

1

Pagina 1 — Introducao + Dataset (~1 pagina)

O que é o HFI, quem coletou (Cato Institute), período 2008-2016, número de países e variáveis. Sua pergunta de pesquisa. Cite Vasquez & McMahon e Sen.

2

Paginas 2-3 — Metodos (~1.5 paginas)

Subseção preparação dos dados: filtrou 2016, removeu NAs, padronizou. Subseção PCA: o que é, por que escolheu, limitações. Subseção Clustering HCPC: o que é, por que escolheu, limitações.

3

Paginas 4-5 — Resultados: PCA (~1.5 paginas)

Scree plot + quantos componentes reteve e por que. Correlation circle. Mapa dos países. PC1 e PC2 nomeados com justificativa. Use seus gráficos reais.

4

Paginas 5-6 — Resultados: Clustering (~1.5 paginas)

Quantos clusters o HCPC sugeriu. Quais países em cada cluster. Caracterização de cada cluster. Plot dos clusters. Interpretação substantiva.

5

Pagina 7 — Discussao + Conclusao (~1 pagina)

O que os resultados sugerem. Conectar com Sen. Limitações honestas. Conclusão de 2-3 frases.

6

Appendix — Codigo R comentado

Todo o código com comentários explicando cada decisão. Não conta nas 7 páginas mas é obrigatório.

Como Interpretar os Resultados

Esta é a parte mais importante. O método das coordenadas — você dá o significado. Escreva o que VOCE vê nos gráficos, com base nos países que aparecem em cada região.

4.1 Como nomear PC1 e PC2

Olhe o gráfico de contribuições. Quais variáveis estão acima da linha tracejada? Em que direção apontam no correlation circle? Depois use este template:

```
"PC1 (X% of variance) appears to represent an axis from [lado esquerdo]
to [lado direito], with variables such as [X, Y] loading positively
and [Z, W] loading negatively. We label this dimension [NOME]."

"PC2 (X% of variance) contrasts [parte de cima] against [parte de baixo].
Countries scoring high on PC2 tend to be [descricao].
We label this dimension [NOME]."
```

4.2 Como caracterizar os clusters

```
"Cluster 1 (N = X countries) is characterized by high [variavel]
scores (mean = X). This cluster includes countries such as
[pais1, pais2, pais3], consistent with [observacao substantiva]."
```

4.3 Tom correto — nota A vs nota baixa

Escreva ASSIM (nota A)	NAO escreva assim
"The results suggest that..."	"The results prove that..."
"PC1 appears to represent..."	"PC1 definitivamente e..."
"We caution that results are exploratory"	"Nossa análise confirma que..."
"Countries in Cluster 1 tend to have..."	"Os países do Cluster 1 são..."

Capítulo 5

Código R Completo e Comentado

Copie e cole no R. Ajuste os nomes das colunas conforme o codebook. Execute passo a passo e olhe cada gráfico antes de continuar.

5.1 Setup

```
# Instalar pacotes – só uma vez
install.packages(c("FactoMineR", "factoextra", "tidyverse"))
# Carregar – toda sessão
library(FactoMineR); library(factoextra); library(tidyverse)
```

5.2 Carregar e explorar

```
# Carregar o CSV
hfi <- read.csv("hfi2008_2016.csv", stringsAsFactors = FALSE)
# Explorar
str(hfi); dim(hfi); head(hfi); names(hfi)
```

5.3 Preparar os dados

```
# Filtrar só 2016 – um país por linha
hfi_2016 <- hfi %>% filter(year == 2016)
# Remover colunas não-numéricas
hfi_num <- hfi_2016 %>%
  select(-year, -ISO_code, -countries, -region) %>%
  select(where(is.numeric))
# Remover NAs – PCA não funciona com NAs
hfi_clean <- na.omit(hfi_num)
# Guardar nomes dos países para os gráficos
country_names <- hfi_2016 %>%
  filter(complete.cases(select(., -year, -ISO_code, -countries, -region))) %>%
  pull(countries)
rownames(hfi_clean) <- country_names
# Verificar
dim(hfi_clean); head(rownames(hfi_clean))
```

5.4 PCA

```
# scale.unit=TRUE: padroniza — OBRIGATORIO para PCA
pca_res <- PCA(hfi_clean, scale.unit=TRUE, graph=FALSE)
# Eigenvalues e variancia explicada
pca_res$eig
summary(pca_res)
```

5.5 Graficos PCA

```
# 1. Scree plot
fviz_eig(pca_res, addlabels=TRUE, ncp=10, main="Scree Plot")
# 2. Correlation circle
fviz_pca_var(pca_res, col.var="contrib",
gradient.cols=c("grey70","steelblue","red"),
repel=TRUE, main="Variable Factor Map")
# 3. Contribuicoes
fviz_contrib(pca_res, choice="var", axes=1, main="Contributions to PC1")
fviz_contrib(pca_res, choice="var", axes=2, main="Contributions to PC2")
# 4. Mapa dos paises
fviz_pca_ind(pca_res, label="all", repel=TRUE,
col.ind="cos2", gradient.cols=c("grey70","steelblue","red"),
main="Countries in PCA Space")
# 5. Biplot
fviz_pca_biplot(pca_res, label="var",
col.ind="steelblue", col.var="red",
repel=TRUE, main="PCA Biplot")
```

5.6 Clustering

```
# HCPC: clustering no espaco PCA
hcpc_res <- HCPC(pca_res, nb.clust=-1, graph=FALSE)
# Paises por cluster
cluster_membership <- hcpc_res$data.clust %>%
  rownames_to_column("country") %>%
  select(country, clust) %>% arrange(clust)
print(cluster_membership)
# Quantos paises por cluster
table(hcpc_res$data.clust$clust)
# Medias por cluster – para caracterizacao no paper
hcpc_res$data.clust %>% group_by(clust) %>%
  summarise(across(where(is.numeric), mean, na.rm=TRUE))
# Plot dos clusters
fviz_cluster(hcpc_res, repel=TRUE,
  show.clust.cent=TRUE, main="Country Clusters in PCA Space")
```

Capítulo 6

Checklist Final — antes de submeter

Verifique cada item antes de converter para PDF e submeter no Lisam.

Item	Verificar	OK?
Formato	~7 paginas sem appendix, espacamento 1.5	☐
PDF	Username LiU no nome, ex: patro10_project2.pdf	☐
Prazo	Lisam → Submissions antes de sexta 12 jun 23:59	☐
Parte 1	Descricao do dataset + pergunta + literatura citada	☐
Parte 2	PCA E clustering (2 metodos EDA confirmados)	☐
Parte 3	Justificativa da escolha + limitacoes de cada metodo	☐
Parte 4a	PC1 e PC2 nomeados e interpretados com justificativa	☐
Parte 4b	Clusters caracterizados com paises exemplos e medias	☐
Parte 5	Limitacoes discutidas honestamente	☐
Appendix	Codigo R completo com comentarios em cada bloco	☐
Tom	Usa "suggests" nao "proves" no texto todo	☐
SQL	SQL nao contado como EDA — so como preparacao de dados	☐

Nota A vem de interpretacao inteligente e escrita honesta — nao de analise tecnicamente perfeita. Carl quer ver voce raciocinar sobre os dados, nao so executar o codigo.

Boa sorte!